

Máy đánh bạc nhiều tay

k-armed bandit

Trần Minh Khôi

Đại học Bách Khoa, TP.HCM

TP.HCM, tháng 4 năm 2026



Mục lục

- 1 Bài toán k-armed bandit
- 2 Khái niệm và ý nghĩa
- 3 Phương pháp Action-Value
- 4 Greedy và ϵ -Greedy
- 5 10-armed Testbed
- 6 Bài toán Nonstationary

Mục lục

- 1 Bài toán k-armed bandit
- 2 Khái niệm và ý nghĩa
- 3 Phương pháp Action-Value
- 4 Greedy và ϵ -Greedy
- 5 10-armed Testbed
- 6 Bài toán Nonstationary



Giới thiệu bài toán

states	actions			
	a_0	a_1	a_2	$\dots$
s_0	$Q(s, a_0)$	$Q(s, a_1)$	$Q(s, a_2)$	$\dots$
s_1	$Q(s, a_0)$	$Q(s, a_1)$	$Q(s, a_2)$	$\dots$
s_2	$Q(s, a_0)$	$Q(s, a_1)$	$Q(s, a_2)$	$\dots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Bài toán k-armed bandit (máy đánh bạc k tay) mô hình hóa tình huống bạn đứng trước k lựa chọn, mỗi lựa chọn tương ứng với một “cần gạt” (arm) của máy đánh bạc.

- Mỗi lần bạn chọn một hành động $A_t \in \{1, 2, \dots, k\}$

Giới thiệu bài toán

states	actions			
	a_0	a_1	a_2	$\dots$
s_0	$Q(s, a_0)$	$Q(s, a_1)$	$Q(s, a_2)$	$\dots$
s_1	$Q(s, a_0)$	$Q(s, a_1)$	$Q(s, a_2)$	$\dots$
s_2	$Q(s, a_0)$	$Q(s, a_1)$	$Q(s, a_2)$	$\dots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Bài toán k-armed bandit (máy đánh bạc k tay) mô hình hóa tình huống bạn đứng trước k lựa chọn, mỗi lựa chọn tương ứng với một “cần gạt” (arm) của máy đánh bạc.

- Mỗi lần bạn chọn một hành động $A_t \in \{1, 2, \dots, k\}$
- Bạn nhận được một phần thưởng ngẫu nhiên R_t .

Giới thiệu bài toán

states	actions			
	a_0	a_1	a_2	$\dots$
s_0	$Q(s, a_0)$	$Q(s, a_1)$	$Q(s, a_2)$	$\dots$
s_1	$Q(s, a_0)$	$Q(s, a_1)$	$Q(s, a_2)$	$\dots$
s_2	$Q(s, a_0)$	$Q(s, a_1)$	$Q(s, a_2)$	$\dots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Bài toán k-armed bandit (máy đánh bạc k tay) mô hình hóa tình huống bạn đứng trước k lựa chọn, mỗi lựa chọn tương ứng với một “cần gạt” (arm) của máy đánh bạc.

- Mỗi lần bạn chọn một hành động $A_t \in \{1, 2, \dots, k\}$
- Bạn nhận được một phần thưởng ngẫu nhiên R_t .
- Mỗi hành động có phân phối phần thưởng riêng, nhưng bạn không biết trước.



Mục tiêu: Tối đa hóa tổng phần thưởng tích lũy theo thời gian.

¹Reinforcement Learning – Học tăng cường

²Thử các hành động mới để thu thập thông tin

³Chọn hành động tốt nhất đã biết

Mục tiêu: Tối đa hóa tổng phần thưởng tích lũy theo thời gian. Đây là mô hình đơn giản nhất của RL ¹ vì

¹Reinforcement Learning – Học tăng cường

²Thử các hành động mới để thu thập thông tin

³Chọn hành động tốt nhất đã biết

Mục tiêu: Tối đa hóa tổng phần thưởng tích lũy theo thời gian. Đây là mô hình đơn giản nhất của RL ¹ vì

- Không có trạng thái (state).
- Không có chuỗi trạng thái.
- Tập trung vào exploration² vs exploitation ³.

¹Reinforcement Learning – Học tăng cường

²Thử các hành động mới để thu thập thông tin

³Chọn hành động tốt nhất đã biết

Mục lục

- 1 Bài toán k-armed bandit
- 2 **Khái niệm và ý nghĩa**
- 3 Phương pháp Action-Value
- 4 Greedy và ϵ -Greedy
- 5 10-armed Testbed
- 6 Bài toán Nonstationary

Giá trị thực của hành động

Giá trị kỳ vọng thật của hành động a được định nghĩa:

$$q_*(a) = \mathbb{E}[R_t \mid A_t = a]$$

Đây là giá trị ta **không biết trước** và cần ước lượng.
Tại mỗi thời điểm t :

- Agent chọn hành động A_t
- Nhận phần thưởng R_t

Ước lượng giá trị hành động

Tại thời điểm t , ta dùng:

$$Q_t(a)$$

để ước lượng $q_*(a)$ dựa trên các phần thưởng đã quan sát.

Examples

- A_t : hành động tại thời điểm t
- R_t : phần thưởng nhận được
- $N_t(a)$: số lần chọn hành động a
- $Q_t(a)$: giá trị ước lượng của hành động a

Các ký hiệu này là nền tảng cho các phương pháp như **greedy** và **ϵ -greedy**.

Khái niệm và ý nghĩa

Tối đa hóa phần thưởng

Mục tiêu là tối đa hóa tổng phần thưởng:

$$\sum_{t=1}^T R_t$$

Tối thiểu hóa regret

Tương đương, ta có thể tối thiểu hóa:

$$\rho = T \cdot q_*(a^*) - \sum_{t=1}^T R_t$$

a

^alà hành động tối ưu (có giá trị kỳ vọng lớn nhất).

Mục lục

- 1 Bài toán k-armed bandit
- 2 Khái niệm và ý nghĩa
- 3 Phương pháp Action-Value**
- 4 Greedy và ϵ -Greedy
- 5 10-armed Testbed
- 6 Bài toán Nonstationary



Phương pháp Action-Value

Trong phần này, chúng ta sẽ xác định true (actual) value của hành động a là $q(a)$, và estimated value trong bước thứ t là $Q_t(a)$. Nhận định rằng, giá trị true value của một hành động sẽ là giá trị trung bình nhận được khi lựa chọn một hành động.

Phương pháp Action-Value

Trong phần này, chúng ta sẽ xác định true (actual) value của hành động a là $q(a)$, và estimated value trong bước thứ t là $Q_t(a)$. Nhận định rằng, giá trị true value của một hành động sẽ là giá trị trung bình nhận được khi lựa chọn một hành động. Một trong những phương pháp phổ thông để xác định giá trị này chính là phương pháp tính giá trị trung bình reward khi một hành động được lựa chọn. Với cách hiểu khác, nếu trong bước thứ t , hành động a được chọn $N_t(a)$ lần cho tới thời gian t , khởi tạo lên một chuỗi $R_1, R_2, \dots, R_{N_t(a)}$, thì value sẽ được dự đoán bằng công thức:



Phương pháp Action-Value

Trong phần này, chúng ta sẽ xác định true (actual) value của hành động a là $q(a)$, và estimated value trong bước thứ t là $Q_t(a)$. Nhận định rằng, giá trị true value của một hành động sẽ là giá trị trung bình nhận được khi lựa chọn một hành động. Một trong những phương pháp phổ thông để xác định giá trị này chính là phương pháp tính giá trị trung bình reward khi một hành động được lựa chọn. Với cách hiểu khác, nếu trong bước thứ t , hành động a được chọn $N_t(a)$ lần cho tới thời gian t , khởi tạo lên một chuỗi $R_1, R_2, \dots, R_{N_t(a)}$, thì value sẽ được dự đoán bằng công thức:

$$Q_t(a) = \frac{R_1 + R_2 + \dots + R_{N_t(a)}}{N_t(a)}.$$

Law of Large Numbers (LLN)

Định lý (Luật số lớn yếu)

Giả sử $X_1, X_2, \dots, X_n$ là các biến ngẫu nhiên độc lập cùng phân phối (i.i.d), với:

$$\mathbb{E}[X_i] = \mu, \quad \text{Var}(X_i) = \sigma^2 < \infty$$

Khi đó, trung bình mẫu:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

hội tụ về kỳ vọng thật:

$$\bar{X}_n \xrightarrow{P} \mu \quad \text{khi } n \rightarrow \infty$$



Phát biểu:

$$P(|X - \mathbb{E}(X)| \geq r) \leq \frac{\text{Var}(X)}{r^2}, \quad r > 0$$

Ý nghĩa: Xác suất để biến ngẫu nhiên X lệch khỏi kỳ vọng $E(X)$ một lượng không nhỏ hơn r bị chặn trên bởi $V(X)/r^2$.

Chứng minh.

Đặt A là biến cố

$$A = \{s \in S \mid |X(s) - E(X)| \geq r\}.$$

Điều cần chứng minh là

$$p(A) \leq \frac{V(X)}{r^2}.$$

Ta bắt đầu từ định nghĩa của phương sai $V(X)$.

Theo định nghĩa, phương sai của X là

$$V(X) = \sum_{s \in S} (X(s) - E(X))^2 p(s).$$

Ta tách tổng trên thành hai phần theo biến cố A :

$$V(X) = \underbrace{\sum_{s \in A} (X(s) - E(X))^2 p(s)}_{\text{tổng thứ nhất}} + \underbrace{\sum_{s \notin A} (X(s) - E(X))^2 p(s)}_{\text{tổng thứ hai}}.$$

- **Tổng thứ hai** $\sum_{s \notin A} (X(s) - E(X))^2 p(s)$ **không âm**, vì mỗi số hạng đều không âm. Do đó:

$$V(X) \geq \sum_{s \in A} (X(s) - E(X))^2 p(s).$$

- **Tổng thứ nhất:** với mọi $s \in A$, theo định nghĩa của A ta có $(X(s) - E(X))^2 \geq r^2$, nên:

$$\sum_{s \in A} (X(s) - E(X))^2 p(s) \geq \sum_{s \in A} r^2 p(s) = r^2 p(A).$$

Chứng minh

Kết hợp hai đánh giá trên, ta được:

$$V(X) \geq r^2 p(A).$$

Chia cả hai vế cho $r^2 > 0$:

$$\frac{V(X)}{r^2} \geq p(A),$$

tức là

$$p(A) \leq \frac{V(X)}{r^2}.$$

Điều này hoàn tất chứng minh.



Nếu $N_t(a) = 0$, thì ta sẽ đặt $Q_t(a)$ bằng một giá trị mặc định nào đó, có thể là bằng 0. Với $N_t(x)$ tiến tới vô cùng, bởi lý thuyết của của đại số, $Q_t(x)$ sẽ hội tụ về $q(a)$ (*****).

Nếu $N_t(a) = 0$, thì ta sẽ đặt $Q_t(a)$ bằng một giá trị mặc định nào đó, có thể là bằng 0. Với $N_t(x)$ tiến tới vô cùng, bởi lý thuyết của của đại số, $Q_t(x)$ sẽ hội tụ về $q(a)(*)$. Đây được gọi là **phương pháp sample-average** cho dự đoán action values do mỗi lần đưa ra dự đoán là một lần dự đoán action values, và nó không hoàn toàn cần đến giá trị tốt nhất. Mặc dù vậy thì ta vẫn sử dụng phương pháp đơn giản trên để đưa ra các lựa chọn cho hành động.

Chứng minh (*):

Giả sử các phần thưởng $X_1, X_2, \dots, X_n$ là các biến ngẫu nhiên độc lập cùng phân phối với kỳ vọng $\mathbb{E}[X_i] = q(a)$ và phương sai hữu hạn $\text{Var}(X_i) = \sigma^2$. Khi đó, ước lượng sample-average:

$$Q_t(a) = \frac{1}{n} \sum_{i=1}^n X_i$$

Ta có:

$$\mathbb{E}[Q_t(a)] = q(a), \quad \text{Var}(Q_t(a)) = \frac{\sigma^2}{n}.$$

Áp dụng bất đẳng thức Chebyshev:

$$\mathbb{P}(|Q_t(a) - q(a)| \geq \varepsilon) \leq \frac{\text{Var}(Q_t(a))}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}.$$

Khi $n \rightarrow \infty$ thì vế phải tiến về 0, do đó: $Q_t(a) \xrightarrow{\mathbb{P}} q(a)$.

Vậy $Q_t(a)$ hội tụ về $q(a)$ theo xác suất (theo luật số lớn yếu).

Mục lục

- 1 Bài toán k-armed bandit
- 2 Khái niệm và ý nghĩa
- 3 Phương pháp Action-Value
- 4 Greedy và ϵ -Greedy**
- 5 10-armed Testbed
- 6 Bài toán Nonstationary

Một trong các phương pháp nhất trong việc xây dựng lên cách lựa chọn action là chọn action với giá trị action value là lớn nhất, để lựa chọn hành động trong bước t của các greedy actions, A_t^* , với mỗi

Một trong các phương pháp nhất trong việc xây dựng lên cách lựa chọn action là chọn action với giá trị action value là lớn nhất, để lựa chọn hành động trong bước t của các greedy actions, A_t^* , với mỗi

$$Q_t(A_t^*) = \max_a Q_t(a)$$

Hành động lựa chọn greedy action này có thể viết dựa dạng:

Một trong các phương pháp nhất trong việc xây dựng lên cách lựa chọn action là chọn action với giá trị action value là lớn nhất, để lựa chọn hành động trong bước t của các greedy actions, A_t^* , với mỗi

$$Q_t(A_t^*) = \max_a Q_t(a)$$

Hành động lựa chọn greedy action này có thể viết dựa dạng:

$$A_t = \operatorname{argmax}_a Q_t(a)$$


Mục lục

- 1 Bài toán k-armed bandit
- 2 Khái niệm và ý nghĩa
- 3 Phương pháp Action-Value
- 4 Greedy và ϵ -Greedy
- 5 10-armed Testbed**
- 6 Bài toán Nonstationary



10-armed Testbed

Để có thể thử nghiệm được tính hiệu quả của **greedy** và **ϵ -greedy** action-value methods, Chúng ta sẽ so sánh trên một tập các test problems. Đây là một tập gồm 2000 bài **k-armed bandit** ngẫu nhiên với $k = 10$. Với mỗi một bài thì action values $q^*(a)$, $a = 1, \dots, 10$ sẽ được lựa chọn ngẫu nhiên trong một hệ normal (gaussian) distribution với mean 0 và varian 1.



Incremental Implementation

Trong các action-value methods mà chúng ta đã đề cập đến thì ta đều estimate các action values là sample averages của các rewards thu được. Bây giờ, ta sẽ chuyển đổi câu hỏi **làm thế nào tính trung bình một cách hiệu quả nhất**, trong thực tế là với constant memory và constant per-time-step computation.

A simple bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

$$N(a) \leftarrow 0$$

A simple bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

$$N(a) \leftarrow 0$$

Loop forever:

$$A \leftarrow \begin{cases} \arg \max_a Q(a), & \text{with probability } 1 - \varepsilon \\ \text{a random action,} & \text{with probability } \varepsilon \end{cases}$$

A simple bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

$$N(a) \leftarrow 0$$

Loop forever:

$$A \leftarrow \begin{cases} \arg \max_a Q(a), & \text{with probability } 1 - \varepsilon \\ \text{a random action,} & \text{with probability } \varepsilon \end{cases}$$

$$R \leftarrow \text{bandit}(A)$$

A simple bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

$$N(a) \leftarrow 0$$

Loop forever:

$$A \leftarrow \begin{cases} \arg \max_a Q(a), & \text{with probability } 1 - \varepsilon \\ \text{a random action,} & \text{with probability } \varepsilon \end{cases}$$

$$R \leftarrow \text{bandit}(A)$$

$$N(A) \leftarrow N(A) + 1, Q(A) \leftarrow Q(A) + \frac{1}{N(A)} [R - Q(A)]$$

[View code on GitHub](#)



Mục lục

- 1 Bài toán k-armed bandit
- 2 Khái niệm và ý nghĩa
- 3 Phương pháp Action-Value
- 4 Greedy và ϵ -Greedy
- 5 10-armed Testbed
- 6 Bài toán Nonstationary**

Bài toán Nonstationary

Với phương pháp tính trung bình mà ta đã đề cập tới bên trên là dành cho các bài toán station bandit, là những bài toán mà xác suất reward không hề thay đổi theo thời gian. Như chúng ta đã đề cập tới, phương pháp trên hầu như không hiệu quả đối với các bài toán bất định hình

(**Nonstationary**). Trong các trường hợp đó, nó sẽ hợp lý hơn nếu ta đánh trọng số vào các reward gần và hiện tại hơn là các reward nhận được trong quá khứ. Một trong những phương pháp làm phổ thông nhất hiện nay là sử dụng một hằng số step-size. Cho ví dụ, trong Incremental update rule cho cập nhật các giá trị trung bình Q_n của reward $n - 1$ có thể thay đổi thành

$$Q_{n-1} = Q_n + \alpha [R_n - Q_n]$$

Trong này thì giá trị tham số α thuộc $(0, 1]$ là hằng số. Kết quả của Q_{n+1} sẽ được tính toán bằng trung bình rewards trong quá khứ và giá trị khởi tạo Q_1 :



$$\begin{aligned}
Q_{n+1} &= Q_n + \alpha[R_n - Q_n] \\
&= \alpha R_n + (1 - \alpha)Q_n \\
&= \alpha R_n + (1 - \alpha)[\alpha R_{n-1} + (1 - \alpha)Q_{n-1}] \\
&= \alpha R_n + (1 - \alpha)\alpha R_{n-1} + (1 - \alpha)^2 Q_{n-1} \\
&= \alpha R_n + (1 - \alpha)\alpha R_{n-1} + (1 - \alpha)^2 \alpha R_{n-2} + \cdots + (1 - \alpha)^{n-1} \alpha R_1 + (1 - \alpha)^n Q_1 \\
&= (1 - \alpha)^n Q_1 + \sum_{i=1}^n \alpha (1 - \alpha)^{n-i} R_i
\end{aligned}$$

Chúng ta sẽ gọi là **weighted average** vì tổng của các trọng số là

$$(1 - \alpha)^n + \sum_{i=1}^n \alpha (1 - \alpha)^{n-i} = 1$$

bạn có thể tự kiểm chứng.



Lưu ý rằng trọng số,

$$\alpha (n - i)^{n-i}$$

Sự thay đổi R_i phụ thuộc vào đã có bao nhiêu reward trước đó, $n - i$, như đã quan sát. Với số lượng $1 - \alpha$ là nhỏ hơn 1, trọng số của R_i giảm dần số lần nhận được rewards. Trong thực tế, giá trị trọng số giảm exponentially dựa vào exponent trong $1 - \alpha$.

(Nếu $1 - \alpha = 0$, thì tất cả trọng số sẽ được đánh vào reward mới nhất, R_n , bởi vì chúng ta xác nhận rằng $0^0 = 1$). Cũng chính vì vậy mà phương pháp này đôi khi được gọi là *exponential recency-weighted average*.

Step-size thay đổi theo từng bước

Đôi khi cần thiết khi ta thay đổi tham số step-size với mỗi một step. Hãy đặt

$$\alpha_n(a)$$

là giá trị step-size được sử dụng để tính toán reward nhận được sau lần thứ n lựa chọn hành động a . Lựa chọn

$$\alpha_n(a) = \frac{1}{n}$$

là kết quả trong *sample-average method*, được xác nhận là hội tụ tới true action values bởi định lý đại số.



Sự hội tụ không được đảm bảo với mọi lựa chọn của chuỗi

$$\{\alpha_n(a)\}.$$

Một kết quả phổ biến trong *stochastic approximation theory* đưa ra cho chúng ta một điều kiện để đảm bảo sự hội tụ với xác suất 1:

Điều kiện hội tụ của step-size

Điều kiện để chuỗi step-size $\alpha_n(a)$ đảm bảo hội tụ:

$$\sum_{n=1}^{\infty} \alpha_n(a) = \infty \quad \text{and} \quad \sum_{n=1}^{\infty} \alpha_n^2(a) < \infty$$

- **Điều kiện 1:** Các steps đủ lớn để vượt qua mọi điều kiện khởi tạo hay sự biến động ngẫu nhiên.
- **Điều kiện 2:** Các steps trở nên đủ nhỏ để đảm bảo sự hội tụ.

Sample-average case vs. Constant step-size

Cả hai điều kiện được thỏa mãn trong **sample-average case**:

$$\alpha_n(a) = \frac{1}{n}$$

Nhưng **không** thỏa mãn khi step-size là hằng số:

$$\alpha_n(a) = \alpha$$



Điều kiện 1: $\sum_{n=1}^{\infty} \frac{1}{n} = \infty$

Dùng đánh giá $\ln(1+x) \leq x$, suy ra:

$$\frac{1}{k} \geq \ln\left(1 + \frac{1}{k}\right) = \ln(k+1) - \ln k$$

Cộng từ $k = 1$ đến n , ta được:

$$1 + \frac{1}{2} + \dots + \frac{1}{n+1} \geq \ln(n+1)$$

Vì $\ln(n+1) \rightarrow \infty$ khi $n \rightarrow \infty$:

$$\lim_{n \rightarrow \infty} \left(1 + \frac{1}{2} + \dots + \frac{1}{n+1}\right) = \infty \quad \checkmark$$

Điều kiện 2: $\sum_{n=1}^{\infty} \frac{1}{n^2} < \infty$

Ta có:

$$\sum_{k=1}^n \frac{1}{k^2} = 1 + \sum_{k=2}^n \frac{1}{k^2} \leq 1 + \sum_{k=2}^n \frac{1}{k(k-1)}$$

Phân tích phân số từng phần:

$$= 1 + \sum_{k=2}^n \left(\frac{1}{k-1} - \frac{1}{k} \right) = 1 + 1 - \frac{1}{n} < 2$$

Chuỗi bị chặn trên và tăng đơn điệu, suy ra:

$$\sum_{n=1}^{\infty} \frac{1}{n^2} < \infty \quad \checkmark$$

Ý nghĩa của constant step-size

Khi $\alpha_n(a) = \alpha$ (hằng số):

- Điều kiện thứ hai **không** được thỏa mãn.
- Việc dự đoán sẽ **không bao giờ** hoàn toàn hội tụ.
- Dự đoán liên tục thay đổi để thỏa mãn với các rewards nhận được **gần nhất**.
- Điều này **có lợi** trong các *nonstationary environment*.
- Vấn đề nonstationary rất phổ biến trong *reinforcement learning*.

Do đó hằng số α không phải là lựa chọn **tối ưu về lý thuyết**, mà là lựa chọn **tốt nhất về mặt thực tiễn** – đơn giản, hiệu quả, dễ kiểm soát.

A simple nonstationary bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

A simple nonstationary bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

Loop forever:

$$A \leftarrow \begin{cases} \arg \max_a Q(a), & \text{with probability } 1 - \varepsilon \\ \text{a random action,} & \text{with probability } \varepsilon \end{cases}$$

A simple nonstationary bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

Loop forever:

$$A \leftarrow \begin{cases} \arg \max_a Q(a), & \text{with probability } 1 - \varepsilon \\ \text{a random action,} & \text{with probability } \varepsilon \end{cases}$$

$$R \leftarrow \text{bandit}(A)$$

A simple nonstationary bandit algorithm

Initialize, for $a = 1$ to k :

$$Q(a) \leftarrow 0$$

Loop forever:

$$A \leftarrow \begin{cases} \arg \max_a Q(a), & \text{with probability } 1 - \varepsilon \\ \text{a random action,} & \text{with probability } \varepsilon \end{cases}$$

$$R \leftarrow \text{bandit}(A)$$

$$Q(A) \leftarrow Q(A) + \alpha [R - Q(A)]$$

[▶ View code on GitHub](#)





Multi-armed bandit problem, Wikipedia.

https://en.wikipedia.org/wiki/Multi-armed_bandit



Richard S. Sutton and Andrew G. Barto.

Reinforcement Learning: An Introduction, 2nd Edition, 2018.



OpenAI Documentation.

<https://platform.openai.com/docs>



T. L. Lai and Herbert Robbins.

Asymptotically efficient adaptive allocation rules.

Advances in Applied Mathematics, 6(1):4–22, 1985.



Peter Auer, Nicolò Cesa-Bianchi, and Paul Fischer.

Finite-time Analysis of the Multiarmed Bandit Problem.

Machine Learning, 47(2–3):235–256, 2002.



Cảm ơn các bạn đã lắng nghe!

